

Clasificación Supervisada de Estrellas Variables en el Polo Eclíptico Sur Galáctico con Random Forest

Simón González

1 de junio de 2026

Resumen

En este proyecto se presenta el desarrollo de un modelo de clasificación supervisada basado en el algoritmo Random Forest para categorizar estrellas variables en el polo eclíptico sur Galáctico. Utilizando observaciones fotométricas de 6789 estrellas en las bandas I y V provenientes del catálogo OGLE IV, se agruparon los datos en cuatro superclases: Pulsantes, Eclipsantes, Variables de Período Largo (LPV) y Other. Para la separación de estas clases se extrajeron cuatro features principales tales como Skewness, Amplitud, Color V-I e Índice von Neumann. El modelo alcanzó una exactitud global del 93 % sobre el conjunto de validación, la cual ascendió a un 97 % al evaluar el desempeño de manera exclusiva sobre las clases físicas bien definidas (excluyendo Other). Los resultados demuestran la alta capacidad de generalización del Random Forest para clasificar estrellas variables, evidenciando simultáneamente las limitaciones del aprendizaje supervisado frente a clases compuestas por poblaciones mixtas o etiquetas poco definidas. Para acceder al código, visite la carpeta *Final: Clasificación de Estrellas Variables Polo Eclíptico Sur* el repositorio de GitHub: <https://github.com/sgonzalez38/Astrofisica-Observacional-con-Machine-Learning>.

1. Introducción

El estudio morfológico y estadístico de las estrellas variables proporciona información relevante para comprender los mecanismos de evolución estelar, la dinámica de las atmósferas astrofísicas y la estructura a gran escala de nuestra Galaxia. Sin embargo, la caracterización individualizada mediante la inspección visual clásica resulta completamente impracticable ante el flujo masivo de datos que caracteriza a la astronomía moderna. En este contexto, los métodos computacionales automatizados surgen como alternativa viable para procesar catálogos a gran escala, permitiendo no solo optimizar el tiempo de análisis, sino también descubrir regularidades estadísticas en los datos temporales de manera objetiva [1].

No obstante, la transición desde los datos fotométricos hasta un clasificador automatizado robusto impone desafíos metodológicos rigurosos. La variabilidad registrada por los detectores mezcla fenómenos astrofísicos intrínsecos con efectos geométricos de la línea de visión y fluctuaciones puramente instrumentales. Por esta razón, el problema no reside únicamente en la elección del algoritmo predictivo, sino en una cuidadosa feature engineering. El propósito fundamental es mapear las series temporales fotométricas en un espacio de parámetros dimensionalmente reducido, donde las distribuciones estelares exhiban un comportamiento segregado y los algoritmos puedan trazar fronteras de decisión estables.

Para abordar esta problemática, el presente informe se estructura de la siguiente manera: en primer lugar, se describe el origen de los datos astronómicos y el proceso de agrupación jerárquica para consolidar las superclases de estudio. A continuación, se definen matemáticamente los features seleccionados a partir de las curvas de luz de OGLE IV [2], justificando la depuración del espacio de parámetros mediante un análisis de correlación lineal. Finalmente, se expone la arquitectura del modelo basado en Random Forest [3], discutiendo sus resultados cualitativos y cuantitativos a través de matrices de confusión, evaluando el impacto del ruido y demostrando la capacidad de generalización del clasificador sobre conjuntos de validación independientes.

2. Objetivos

- Diseñar features para la clasificación multiclase de estrellas variables en el polo eclíptico sur Galáctico.
- Diseñar un algoritmo de Random Forest para la clasificación supervisada de estrellas variables.
- Evaluar el desempeño del algoritmo sobre el conjunto de validación.

3. Procedimiento

Los datos fotométricos del polo sur eclíptico de la Galaxia fueron obtenidos del catálogo OGLE IV [2]. En total se descargaron 6789 estrellas con sus respectivas etiquetas ground truth y sus datos fotométricos en banda I y V. Se descargaron estrellas pertenecientes a la clase RR Lyrae, Long Period Variable, Binarias Eclipsantes, Elipsoidales, Delta Scuti, Delta Cepheid, Cefeidas tipo II, Cefeidas Anomalias y otras catalogadas dentro de la clase Other.

3.1. Proceso de Etiquetado

Como se mencionó anteriormente se encontraron 9 clases, de las cuales se eliminaron algunas y se juntaron otras para crear super clases. Debido a su poca representación, se eliminaron las clases Cefeida Tipo II y Anomalas, puesto que no cumplen con el criterio de contar con suficientes datos para realizar la tarea de la clasificación supervisada. Por otro lado, las clases RR Lyrae, Delta Scuti y Delta Cepheid se juntaron en una super clase denominada Pulsantes. Mientras que las Binarias Eclipsantes y las Elipsoidales se juntaron en la super clase Eclipsantes. De esta manera, la clasificación supervisada se hizo sobre las super clases Pulsantes, Eclipsantes, Long Period Variable (LPV) y Other.

La figura 1 muestra un histograma que refleja la cantidad de estrellas por super clase, en la cual se puede apreciar que LPV contiene un mayor número de estrellas, mientras que las Eclipsantes son minoría.




Figura 1: Histograma de superclases.

3.2. Elección de Features

Uno de los factores más importantes para una buena clasificación supervisada es la elección de features, pues se requiere que estas logren diferenciar bien los miembros de las clases que se quieren diferenciar. En este caso, se eligieron en principio 5 features relacionadas con los datos fotométricos: Kurtosis, skewness, la amplitud en magnitudes, el color V-I y el índice Von Neumann. Cada uno de estos se describe a continuación.

1. **Kurtosis:** Cuantifica el grado de apuntamiento de la distribución de magnitudes y el peso de sus colas en comparación con una distribución normal. Se define matemáticamente como:

$$\gamma_2 = \frac{\frac{1}{N} \sum_{i=1}^N (m_i - \bar{m})^4}{\left[\frac{1}{N} \sum_{i=1}^N (m_i - \bar{m})^2 \right]^2} - 3 \quad (1)$$

Donde m_i representa la magnitud en la observación i , $\bar{m}$ es la magnitud promedio y N es el número total de observaciones. En nuestro caso, una kurtosis elevada es un indicador útil para identificar binarias eclipsantes de corto ciclo o estrellas con estallidos esporádicos, mientras que los pulsadores continuos (como las Cefeidas) exhiben valores bajos o negativos debido a sus perfiles de variación suaves.

2. **Skewness:** Mide el grado de asimetría de la distribución de magnitudes respecto a su media. Su expresión matemática corresponde al tercer momento estandarizado:

$$\gamma_1 = \frac{\frac{1}{N} \sum_{i=1}^N (m_i - \bar{m})^3}{\left[\frac{1}{N} \sum_{i=1}^N (m_i - \bar{m})^2 \right]^{3/2}} \quad (2)$$

En nuestro caso, una estrella que permanece la mayor parte del tiempo en su nivel base y sufre caídas de luz rápidas y profundas, como las eclipsantes, presentará una cola hacia magnitudes altas, resultando en un skewness fuertemente positivo. Por el contrario, fenómenos de flares generan un skewness negativo.

3. **Amplitud:** En lugar de utilizar el rango dinámico absoluto ($\Delta m = m_{max} - m_{min}$), el cual es altamente sensible a errores fotométricos individuales o rayos cósmicos en el detector CCD, se implementó una métrica robusta basada en percentiles:

$$A_{95} = P_{95}(m) - P_5(m) \quad (3)$$

Donde P_{95} y P_5 representan los percentiles 95 y 5 de la distribución de magnitudes, respectivamente. Esta variable actúa como un descriptor de la energía del sistema, aislando de forma eficiente a las LPV, cuyas amplitudes varían en varios enteros de magnitud, de los micropulsadores (como las estrellas Delta Scuti) o de estrellas no variables de la clase Other.

4. **Color ($V - I$):** Es una propiedad calculada como la diferencia entre la magnitud media ponderada de la estrella en la banda visible V y la banda del infrarrojo cercano I:

$$C_{V-I} = \langle m_V \rangle - \langle m_I \rangle \quad (4)$$

El índice de color es un indicador directo de la temperatura efectiva de la fotosfera estelar. En nuestro esquema de clasificación, es la herramienta que permite resolver la degeneración entre la clase Other₄ y las LPVs. Las LPVs son gigantes rojas

evolutivamente avanzadas y frías, por lo que el color $V - I$ es positivo, mientras que los objetos de la clase Other (como las estrellas Be) son masivos, jóvenes y calientes, ubicándose en zonas de color bajo o cercano a cero.

5. **Índice von Neumann:** Corresponde al cociente entre el cuadrado medio de las diferencias sucesivas de la serie temporal y su varianza global [4]. Su expresión formal adaptada a curvas de luz astronómicas es:

$$\eta = \frac{\sum_{i=1}^{N-1} (m_{i+1} - m_i)^2}{(N - 1) \cdot \sigma^2} \quad (5)$$

Donde σ^2 es la varianza muestral de las magnitudes. Este parámetro evalúa la correlación temporal consecutiva de la serie temporal fotométrica [5]. Un valor de $\eta \approx 2$ implica que no existe correlación entre una observación y la siguiente, comportamiento característico del ruido blanco instrumental. Esto permite segregar estadísticamente a las estrellas no variables dentro de la clase Other. Por otro lado, cualquier estrella variable exhibirá transiciones suaves y continuas en el tiempo, lo que colapsa el índice hacia valores cercanos a cero ($\eta \ll 1$).

Sin embargo, puede ocurrir que algunas features estén correlacionadas y por tanto aporten información redundante en el modelo. Para comprobar esto se calculó la matriz de correlación que se muestra en la figura 2. Tal como se observa, la kurtosis y el skewness están altamente correlacionados, mientras que el índice Von Neumann y el Color exhiben una correlación altamente negativa. Esto indica que podemos eliminar alguna de las dos variables correlacionadas sin impactar en gran medida el modelo predictivo. Sin embargo, de manera empírica encontramos que es importante conservar tanto el Color como el índice Von Neumann, aunque sí podemos prescindir de la kurtosis.




Figura 2: Matriz de correlación entre las features.

Teniendo esto en cuenta, al final se usaron solo 4 de las 5 features propuestas. La figura 3 muestra los histogramas de cada feature por super clase, con el fin de demostrar que sí son capaces de diferenciar entre super clases. Tal como se mencionó, el skewness permite diferenciar las Eclipsantes de las demás estrellas, la amplitud permite diferenciar las pulsantes y eclipsantes, el índice Von Neumann permite diferenciar las LPV y las pulsantes, mientras que el color diferencia entre LPV y eclipsantes. Sin embargo, el histograma de la feature Color muestra un comportamiento bastante peculiar en cuanto a la super clase Other, el cual estudiaremos con mayor detalle a continuación.




Figura 3: Histogramas de cada feature por super clase.

3.3. Estudio de la clase Other

La figura 4 muestra el histograma de Color para la super clase Other. En dicho histograma es posible observar dos tendencias principales cuyos picos están aproximadamente en el color 0 y 1.2. Recordemos que esta super clase contiene estrellas que no se pudieron clasificar dentro de las demás clases, por lo que contiene tanto estrellas no variables, como estrellas Be y otras con un claro indicador de variabilidad pero que no cumplen con las características de pulsadores radiales o eclipsantes.




Figura 4: Histograma de la feature Color para la super clase Other.

De esta manera, a diferencia de las demás super clases, las estrellas pertenecientes a Other son distintas entre sí pues al menos existen dos subclases dentro de esta super clase. Esto dificulta en gran medida la clasificación supervisada de estas estrellas, pues el modelo puede confundirlas y clasificarlas dentro de las demás clases, lo que disminuye la precisión y exactitud del clasificador.

3.4. Diseño del modelo Random Forest

El modelo predictivo escogido para la clasificación supervisada fue Random Forest [3]. Este algoritmo, perteneciente a la familia de métodos de aprendizaje automático por ensambl, opera mediante la construcción de una multitud de árboles de decisión independientes durante la fase de entrenamiento, determinando la clasificación final a través de un voto mayoritario (la moda de las clases) de los árboles individuales.

El funcionamiento del Random Forest se basa en la inyección de aleatoriedad en dos niveles fundamentales para garantizar la robustez y minimizar el error de generalización del modelo:

1. **Agregación por Bootstrap (*Bagging*):** Cada árbol en el bosque se entrena utilizando una muestra aleatoria con reemplazo extraída del conjunto de datos original [6]. Esto implica que cada árbol observa una distribución ligeramente diferente de las estrellas en el catálogo. Este proceso reduce drásticamente la varianza del modelo global y mitiga el riesgo de overfitting provocado por observaciones ruidosas o outliers fotométricos.

2. **Selección Aleatoria de Características:** A diferencia de un árbol de decisión clásico, el cual evalúa todas las variables disponibles para encontrar el corte óptimo en cada nodo, Random Forest selecciona un subconjunto aleatorio de características en cada división [3,7]. Esto fuerza a los árboles a ser estructuralmente diversos y evita que una única característica dominante supere la información valiosa contenida en variables más sutiles.

Para el entrenamiento del modelo se decidió partir el dataset en 80 % entrenamiento y 20 % validación, de modo que se evaluaron 5432 estrellas en el entrenamiento y 1357 en la validación.

3.5. Evaluación del algoritmo

Para evaluar el desempeño del Random Forest se calcularon métricas como la precisión, el recall y el F1-score. La definición de cada una de estas se basa en los Verdaderos Positivos (TV), Falsos Positivos (FP) y Falsos Negativos (FN).

La precisión mide la calidad de las predicciones positivas del modelo. Esta métrica responde a la pregunta: De todos los elementos que el modelo aseguró que pertenecían a una clase, ¿cuántos realmente correspondían a ella?. Matemáticamente se expresa:

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (6)$$

Por otro lado, el recall mide la capacidad del modelo para detectar casos reales pertenecientes a una clase, es decir que responde a la pregunta: De todos los elementos que verdaderamente existen de esta clase en los datos, ¿cuántos logró encontrar el modelo?. Matemáticamente se expresa como:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (7)$$

El F1-score es el promedio armónico entre la precisión y el recall, es decir que es una métrica que balancea ambas propiedades. Matemáticamente se expresa como:

$$\text{F1-Score} = 2 \times \frac{\text{Precisión} \times \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (8)$$

4. Problemas encontrados y soluciones aplicadas

En general, en este informe se encontraron tres problemas fundamentales. El primero relacionado con la tentación a elegir el periodo como feature, el segundo relacionado con la correlación entre features y el tercero relacionado con el overfitting del modelo.

En primer lugar, pareciese bastante natural elegir el periodo como una feature para clasificar las estrellas variables, pues sabemos que las LPV tienen periodos de varios cientos de días mientras que las pulsantes están en rangos de horas o pocos días. Sin embargo, el principal inconveniente es la manera en la que se calculan los periodos mediante el periodograma de Lomb-Scargle, pues esta herramienta usa la frecuencia con mayor potencia para producir la curva de luz plegada. Esto implica que sin una inspección visual detallada podemos asignarle un periodo falso de cientos de días a una estrella no variable de la super clase Other que puede confundirse con una LPV. De manera similar, la curva de luz plegada de una eclipsante puede mostrar el eclipse primario y secundario en la misma fase, etc. Teniendo esto en cuenta, se descartó el periodo como una feature útil para la clasificación de estrellas.

En segundo lugar, como se mencionó previamente, si dos variables están correlacionadas implica que pueden explicar el mismo fenómeno de manera redundante, por lo que tenerlas en cuenta solo aumenta el tiempo de computo. En este caso, se optó por eliminar la kurtosis dado que está correlacionada con el skewness, además el modelo Random Forest le dio menos peso a dicha variable que al skewness. Por otro lado, se encontró de manera empírica que el modelo le da mucho peso al Color y al índice Von Neumann, por lo que a pesar de estar fuertemente correlacionadas de manera negativa, se decidió conservar ambas features.

Finalmente, se trató el problema del overfitting relacionado a la capacidad de generalización del modelo predictivo basado en Random Forest. Dado que se trabajó en un esquema 80 % entrenamiento y 20 % evaluación, decidir los hiperparámetros del modelo es esencial para evitar que este se aprenda los datos y pierda completamente su capacidad de generalización. Por este motivo, se decidió utilizar 100 estimadores con una profundidad máxima de 10 cada uno. Asimismo, los pesos de las clases se configuraron en el modo `balanced`, pues como se mencionó anteriormente, no todas las superclases tienen el mismo número de elementos, por lo que garantizar un peso balanceado a todas las super clases permite una mejor capacidad de generalización.

5. Resultados

Una vez el modelo se entrenó, se le asignaron las importancias mostradas en la tabla 1 a cada una de las cuatro features discutidas previamente. Tal como se puede observar, la feature con mayor importancia es el Color, lo cual se relaciona directamente con su capacidad de distinguir entre las super clases LPV y eclipsantes, como se muestra en la figura 3. El Skewness es la segunda feature con mayor importancia, le sigue la amplitud y finalmente el índice von Neumann. En este sentido, para clasificar una estrella como perteneciente a una super clase, el modelo le da un peso mucho mayor al color que el índice von Neumann, lo cual también está relacionado con la correlación negativa existente entre las dos variables.

Característica (Feature)	Importancia Relativa
Color ($V - I$)	0.3800
Skewness	0.2675
Amplitud	0.1919
Índice von Neumann	0.1606
Total	1.0000

Cuadro 1: Importancia relativa de las features en el modelo Random Forest.

Para evaluar el desempeño del modelo se construyó la matriz de confusión que se muestra en la figura 5. Es posible notar que, evidentemente la super clase con el mayor número de verdaderos positivos es la LPV, debido a que tiene la mayor representación dentro del conjunto de validación. Por otro lado, las Pulsantes exhiben un comportamiento bastante bueno, pues solo 5 estrellas fueron clasificadas de forma errónea. Sin embargo, el modelo presenta un menor rendimiento en la clasificación de las super clases Eclipsantes y Other.

El bajo rendimiento en las Eclipsantes se relaciona con que ninguna feature diferencia completamente esta super clase de las demás, tal como indican los histogramas de la figura 3. A diferencia de las LPV en donde el Color y el índice von Neumann segregan completamente esta clase, las Eclipsantes comparten características similares con las Pulsantes y la super clase Other en cuanto a Color e índice von Neumann, por lo que su principal feature de diferenciación es el Skewness. Al solo tener una feature que las diferencia parcialmente, porque como indica el histograma comparten características con las LPV cerca del Skewness 0, es muy difícil clasificarlas en su totalidad de manera correcta.

Por otra parte, el bajo rendimiento sobre la super clase Other se debe precisamente a que dentro de esta conviven al menos dos poblaciones de estrellas, tal como lo demuestra el histograma de color de la figura 4. Al mismo tiempo, ninguna de las features de los histogramas de la figura 3 diferencia completamente esta clase de las demás, puesto que comparten un Skewness similar a las LPV, la amplitud es similar a las de todas las otras super clases, el índice von Neumann cubre todo el rango entre 0 y 2, y el color presenta dos picos como se mencionó previamente. De esta forma, con las features escogidas no hay forma de clasificar correctamente todas las estrellas catalogadas en Other.




Figura 5: Matriz de confusión calculada sobre los datos de validación. El eje vertical contiene las etiquetas verdaderas, mientras que el horizontal contiene las etiquetas predichas.

Para hacer un análisis cuantitativo del modelo se calcularon las métricas precisión, recall y F1-Score que se muestran en la tabla 2. Es posible observar que la exactitud global del modelo es del 93 %, lo cual es muy bueno teniendo en cuenta la variabilidad de super clases presentes en el dataset. Tal y como se mencionó previamente, el modelo presenta su mejor rendimiento en la super clase LPV con un F1-Score de 97 %, una precisión del 95 % y un recall del 99 %. Asimismo, se evidencia que, a pesar de que la precisión sobre las Pulsantes es baja, el F1-Score es de 95 %, lo que concuerda con las observaciones previas de la matriz de confusión. Las super clases Eclipsantes y Other son las que presentan menor recall y por tanto menor F1-Score, lo cual refuerza de forma cuantitativa los comentarios hechos previamente sobre las features y su baja capacidad de distinguir entre estas super clases.

El modelo también se evaluó sobre el dataset excluyendo la super clase Other, con el objetivo de demostrar que el algoritmo es capaz de clasificar estrellas correctamente etiquetadas. Sobre el nuevo conjunto de entrenamiento se encontraron que las impor-

Superclase	Precisión	Recall	F1-Score	Soporte (N)
Eclipsantes	0.93	0.83	0.88	287
LPV	0.95	0.99	0.97	558
Other	0.87	0.87	0.87	308
Pulsantes	0.92	0.98	0.95	204
Exactitud global (Accuracy)			0.93	1357
Promedio Macro (Macro Avg)	0.92	0.92	0.92	1357
Promedio Ponderado (Weighted Avg)	0.93	0.93	0.92	1357

Cuadro 2: Métricas de evaluación del modelo Random Forest sobre el conjunto de validación. La columna soporte se refiere a la cantidad de estrellas por super clase presentes en el conjunto de validación.

tancias del índice von Neumann y la amplitud variaron considerablemente, como se muestra en la tabla 3. Esto se debe principalmente a que el índice von Neumann de la super clase Other cubre todos los rangos posibles entre 0 y 2, por lo que no aportaba mucha información que ahora si permite diferenciar activamente las LPV de las Eclipsantes y Pulsantes. Lo mismo ocurre con la amplitud, pues como se observa en el histograma de la figura 3, la amplitud de las LPV y las Other era indistinguible.

Característica (Feature)	Importancia Relativa
Color ($V - I$)	0.3622
Skewness	0.3180
Amplitud	0.0889
Índice von Neumann	0.2309
Total	1.0000

Cuadro 3: Importancia relativa de las features en el modelo Random Forest sin la super clase Other.

Para evaluar la capacidad de predicción del modelo se construyó la matriz de confusión de la figura 6. En este caso es posible notar un aumento en el caso de verdaderos positivos en las Eclipsantes y las LPV, para el caso de las Pulsantes se redujo el valor de verdaderos positivos pero no por confusión sino porque en este nuevo conjunto de validación existen 201 estrellas Pulsantes en vez de 204, por lo que el rendimiento del modelo si presentó una mejora.




Figura 6: Matriz de confusión calculada sobre los datos de validación del modelo entrenado sin la clase Other. El eje vertical contiene las etiquetas verdaderas, mientras que el horizontal contiene las etiquetas predichas.

Para evaluar cuantitativamente esta capacidad de predicción se calcularon las métricas que se muestran en la tabla 4. En este caso se puede apreciar que la exactitud global subió a 97 % y el rendimiento por cada super clase también mejoró individualmente. Para el caso de las Eclipsantes la precisión aumentó 5 %, el recall 10 % y el F1-Score 7 %. Para las LPV la precisión aumentó un 3 %, se alcanzó un recall perfecto y el F1-Score aumentó en 2 %. Finalmente, para el caso de las estrellas Pulsantes la precisión aumentó 5 %, el recall disminuyó 2 % y el F1-Score aumentó 1 %. De esta forma, se puede decir que en general el modelo es capaz de realizar labores de clasificación multiclase de estrellas variables cuyas etiquetas están correctamente definidas.

Superclase	Precisión	Recall	F1-Score	Soporte (N)
Eclipsantes	0.97	0.93	0.95	298
LPV	0.98	1.00	0.99	563
Pulsantes	0.97	0.96	0.96	201
Exactitud global (Accuracy)			0.97	1062
Promedio Macro (Macro Avg)	0.97	0.96	0.97	1062
Promedio Ponderado (Weighted Avg)	0.97	0.97	0.97	1062

Cuadro 4: Métricas de evaluación del modelo Random Forest excluyendo la super clase Other.

6. Conclusiones

En este informe hemos desarrollado un clasificador multiclase supervisado para estrellas variables en el polo sur eclíptico de la Galaxia. Para esto primero se utilizaron datos del catálogo OGLE IV y se descargaron 6789 estrellas de 9 clases distintas: RR Lyrae, LPV, Binarias Eclipsantes, Elipsoidales, Delta Scuti, Delta Cepheid, Cefeidas tipo II, Cefeidas Anómalas y estrellas Other. Debido a sus propiedades en común, se decidió agrupar algunas de estas clases en super clases como Eclipsantes (Binarias y Elipsoidales), LPV, Pulsantes (Delta Scuti, Delta Cepheid, RR Lyrae) y Other, así como eliminar las clases con baja representación como las Cefeidas Tipo II y Anomalas.

Ya con las etiquetas definidas se procedió con el diseño de las features de clasificación. En este caso se eligieron cinco features como la Kurtosis, el Skewness, la amplitud, el índice von Neumann y el Color V-I. Sin embargo, luego de un estudio de correlación se decidió descartar la Kurtosis, pues es una variable fuertemente correlacionada al Skewness que aportan la misma información. Con las cuatro features resultantes se construyó un modelo Random Forest que se entrenó con el 80 % de los datos y se validó con el otro 20 %. Los resultados mostraron una exactitud global del 93 %, exhibiendo un mejor rendimiento en la clasificación de LPV y Pulsantes, pero un bajo rendimiento en las Eclipsantes y Other. Este bajo rendimiento se explicó por la incapacidad de las features de distinguir completamente estas dos clases y por la existencia de al menos dos subclases dentro de Other que se comportan de forma muy distinta, lo que impide su clasificación con buena precisión.

Para demostrar que el modelo si logra clasificar las estrellas con un etiquetado certero como LPV, Eclipsantes y Pulsantes, se entrenó el modelo con los mismos datos pero eliminando la super clase Other. En este caso el modelo mejoró su exactitud global a un 97 % y el rendimiento individual de las tres super clases mejoró en promedio un 5 %, lo que demuestra la capacidad de generalización del modelo para la clasificación

de estrellas variables.

Finalmente, el diseño de este algoritmo y su desempeño frente a la clase Other permitió comprender algunas limitaciones de la clasificación supervisada. Pues es necesario que las etiquetas ground truth de los datos estén correctamente definidas por un experto, sino el modelo no logrará aprender las características de los datos de manera correcta y su desempeño no será adecuado.

Referencias

- [1] K. V. Sokolovsky, P. Gavras, A. Karampelas, P. Coravel, *et al.*, “Comparative performance of selected variability detection techniques in photometric time series data,” *Monthly Notices of the Royal Astronomical Society*, vol. 464, no. 1, pp. 274–292, 2017.
- [2] A. Udalski, M. K. Szymański, and G. Szymański, “Ogle-iv: fourth phase of the optical gravitational lensing experiment,” *arXiv preprint arXiv:1504.05966*, 2015.
- [3] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] J. von Neumann, “Distribution of the ratio of the mean square successive difference to the variance,” *The Annals of Mathematical Statistics*, vol. 12, no. 4, pp. 367–395, 1941.
- [5] M.-S. Shin, M. Sekora, and Y.-I. Byun, “Detecting variability in massive astronomical time series data–i. application of an infinite gaussian mixture model,” *Monthly Notices of the Royal Astronomical Society*, vol. 400, no. 4, pp. 1897–1910, 2009.
- [6] L. Breiman, “Bagging predictors,” *Machine Learning*, vol. 24, no. 2, pp. 123–140, 1996.
- [7] T. K. Ho, “The random subspace method for constructing decision forests,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 20, no. 8, pp. 832–844, 1998.