

Estudio de pertenencia de estrellas al cúmulo M41 a partir de datos Gaia DR3

Simón González López

6 de marzo de 2026

Resumen

En este informe se presenta un estudio de pertenencia de estrellas al cúmulo abierto M41 utilizando datos del catálogo Gaia DR3. A partir de una búsqueda en cono de 1° al rededor del cúmulo y un filtrado por paralaje, se obtuvo una muestra de 20000 estrellas. La distribución de movimientos propios en ascensión recta y declinación se modeló mediante dos distribuciones normales bivariadas que representan las poblaciones del cúmulo y el campo. Los parámetros de estas distribuciones se estimaron mediante el método del máxima verosimilitud, optimizado mediante el algoritmo Broyden–Fletcher–Goldfarb–Shanno con memoria limitada. A partir de los parámetros obtenidos se calculó la probabilidad de pertenencia al cúmulo mediante el Teorema de Bayes. Se encontró que 532 estrellas presentan probabilidades de pertenencia mayores a 0.5, por lo que las consideramos como parte del cúmulo M41. El diagrama magnitud-color muestra que estas estrellas siguen claramente la secuencia principal del cúmulo. Los resultados evidencian que el modelo estadístico permite identificar de forma eficiente las estrellas del cúmulo y del campo, aunque también sugieren la conveniencia de incorporar variables adicionales y algoritmos de Machine Learning para mejorar la clasificación de pertenencia. Para acceder al código, visite la carpeta *Lab2: Pertenencia* en el repositorio de GitHub en el siguiente link <https://github.com/sgonzalez38/Astrofisica-Observacional-con-Machine-Learning>.

1. Introducción

Los cúmulos abiertos son sistemas gravitacionalmente ligados formados por estrellas que se originaron a partir de la misma nube molecular. Debido a su origen común, estas estrellas comparten propiedades físicas similares como edad, composición química, distancia y movimiento espacial. Por este motivo, los cúmulos abiertos son ideales para el estudio de la evolución estelar [1, 2].

El cúmulo abierto M41 se localiza en la constelación Canis Major, se ubica a una distancia de 725pc del Sol y su edad se estima en torno a 200 millones de años. Debido a su relativa proximidad y riqueza estelar, M41 es un cúmulo ideal para estudiar la cinemática y composición de los cúmulos abiertos [1].

El estudio moderno de cúmulos abiertos se ha visto potenciado gracias a la misión astrométrica Gaia de la Agencia Espacial Europea. En particular, el catálogo Gaia Data Release 3 (DR3) proporciona mediciones precisas de posiciones, paralajes, movimientos propios y fotometría de diversas estrellas [3]. Estas mediciones permiten determinar con gran precisión las propiedades cinemáticas de las estrellas, y por tanto identificar miembros de cúmulos abiertos con una buena precisión [3].

Una de las magnitudes astrométricas fundamentales proporcionadas por Gaia es el movimiento propio, que describe el desplazamiento angular aparente de una estrella sobre la esfera celeste debido a su movimiento transversal con respecto al Sol [4]. El movimiento propio proporcionado por Gaia se mide en mas/año y se descompone en dos componentes: movimiento propio en ascensión recta $\mu_{\alpha*}$ y el movimiento propio en declinación μ_{δ} . La componente en ascensión recta se define como $\mu_{\alpha*} = \mu_{\alpha} \cos \delta$, lo que corrige la escala de ascensión recta [4]. En un cúmulo abierto, las estrellas miembros comparten aproximadamente el mismo vector de movimiento propio, ya que en promedio se encuentran a la misma distancia y se desplazan juntas a través de la Galaxia. En contraste, las estrellas del campo presentan una distribución mucho más dispersa en el espacio de movimientos propios.

Una representación común de estas distribuciones es el diagrama vectorial de puntos, en el cual cada estrella se representa en el plano de movimientos propios en declinación y ascensión recta. En este espacio, las estrellas del cúmulo tienden a concentrarse alrededor de un punto correspondiente al movimiento medio del sistema, mientras que las estrellas del campo se distribuyen de manera más dispersa. Esta diferencia en las distribuciones permite separar ambas poblaciones mediante métodos estocásticos.

El problema de pertenencia consiste precisamente en determinar qué estrellas observadas pertenecen realmente al cúmulo y cuáles corresponden al campo. Este problema ha sido abordado históricamente mediante modelos estadísticos que describen la distribución de movimientos propios de ambas poblaciones. Un enfoque clásico consiste en modelar la distribución de movimientos propios del cúmulo como una distribución normal bivariada circular, y la del campo como una bivariada elíptica, cuyos parámetros pueden estimarse a partir de los datos observados.

Uno de los métodos usados históricamente fue desarrollado por Vasilevskis et al. (1958) [5] y posteriormente formalizado por Sanders (1971) [6], quienes propusieron un modelo basado en la mezcla de distribuciones normales para representar las poblaciones

del cúmulo y del campo en el diagrama vectorial de puntos. Los parámetros de estas distribuciones se estiman mediante el método de máxima verosimilitud [7], que permite encontrar los valores que maximizan la probabilidad de observar los datos a partir del modelo considerado. Con base en estos parámetros es posible calcular, mediante Teorema de Bayes, la probabilidad de pertenencia de cada estrella al cúmulo.

En este trabajo se aplica el enfoque estadístico descrito previamente, al cúmulo abierto M41, utilizando datos del catálogo Gaia DR3. A partir del análisis de los movimientos propios en ascensión recta y declinación se modelan las distribuciones correspondientes al cúmulo y al campo estelar, estimando sus parámetros mediante el método de máxima verosimilitud. Posteriormente, se calculan las probabilidades de pertenencia individuales para las estrellas observadas, permitiendo identificar los miembros probables del cúmulo y analizar su distribución en el diagrama magnitud-color.

2. Objetivos

- Realizar el estudio de pertenencia de estrellas al cúmulo M41 a partir de los datos Gaia DR3.
- Diseñar distribuciones de probabilidad asociadas al cúmulo y el campo.
- Optimizar un algoritmo de máxima verosimilitud para calcular las probabilidades de que una estrella pertenezca al cúmulo.
- Construir diagramas magnitud-color de las estrellas pertenecientes al cúmulo M41.

3. Procedimiento

Los datos fueron tomados del catálogo Gaia DR3. Para esto se hizo una búsqueda en cono de 1° y se filtró por paralaje. Dado que el cúmulo M41 está ubicado a 725pc y su diámetro es de 8pc, el filtrado por paralaje se hizo en $(725 \pm 30pc)^{-1}$, es decir $1,3245 - 1,4388$ mas, esto con el objetivo de tener estrellas del cúmulo y suficientes estrellas del campo para resolver el problema de pertenencia.

La figura 1 muestra el diagrama vectorial de puntos de las estrellas descargadas del catálogo. Este diagrama es muy importante pues permite identificar densidades asociadas al cúmulo. Esto debido a que, como en promedio las estrellas del cúmulo están a la misma distancia, los movimientos propios en declinación y ascensión recta son muy similares. Es por esto que las estrellas del cúmulo siguen una distribución normal bivariada con la misma desviación en ambos movimientos propios. Por otro lado, las estrellas del campo no se encuentran a la misma distancia, por lo que tienen comportamientos significativamente distintos en cuanto a los movimientos propios. Es

por esta razón que las estrellas del campo se modelan como una distribución bivariada pero con desviaciones distintas para el movimiento propio en declinación y en ascensión recta.




Figura 1: Diagrama Vectorial de puntos cúmulo M41 y estrellas del campo.

Las distribuciones marginales de los movimientos propios en declinación y ascensión recta, mostradas en los histogramas de la figura 1, muestran un pico muy evidente que está relacionado con una de las densidades del diagrama vectorial de puntos. Esto es un indicio claro de que dicha densidad corresponde al cúmulo, pues como se mencionó anteriormente, las estrellas en un cúmulo presentan un comportamiento muy similar en cuanto a los movimientos propios. Adicionalmente, el histograma superior, que co-

responde al movimiento propio en ascensión recta, presenta un segundo pico de menor intensidad que podríamos relacionar con las estrellas del campo que poseen movimientos propios similares.

Tal como se mencionó previamente, las estrellas tanto del cúmulo como del campo siguen una distribución normal bivariada. Más precisamente la distribución de estrellas del cúmulo es:

$$P_c(\mu_x, \mu_y) = \frac{1}{2\pi\sigma^2} \exp \left[-\frac{1}{2} \frac{(\mu_x - \mu_{x0c})^2 + (\mu_y - \mu_{y0c})^2}{\sigma^2} \right] \quad (1)$$

en donde μ_x es el movimiento propio en ascensión recta, μ_y es el movimiento propio en declinación, μ_{x0c} y μ_{y0c} son los centroides de dichos movimientos propios y σ su desviación. Por su parte, la distribución de las estrellas del campo es:

$$P_f(\mu_x, \mu_y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \Theta \right] \quad (2)$$

con

$$\Theta = \left(\frac{(\mu_x - \mu_{x0f})^2}{\sigma_x^2} + \frac{(\mu_y - \mu_{y0f})^2}{\sigma_y^2} - \frac{2\rho(\mu_x - \mu_{x0f})(\mu_y - \mu_{y0f})}{\sigma_x\sigma_y} \right) \quad (3)$$

en donde μ_x es el movimiento propio en ascensión recta, μ_y es el movimiento propio en declinación, μ_{x0f} , μ_{y0f} y σ_x , σ_y son los centroides de dichos movimientos propios y sus desviaciones, respectivamente. Por otro lado ρ es el coeficiente correlación de los movimientos propios.

Las dos distribuciones pueden escribirse sabiendo que la proporción de estrellas en el cúmulo (n_c) y en el campo (n_f) obedecen que $n_c + n_f = 1$, de la siguiente forma:

$$P(\mu_x, \mu_y) = n_c * P_c(\mu_x, \mu_y) + (1 - n_c) * P_f(\mu_x, \mu_y) \quad (4)$$

A partir de la probabilidad condicional, específicamente por el Teorema de Bayes, podemos escribir la probabilidad de que una estrella pertenezca al cúmulo dados sus movimientos propios de la siguiente manera:

$$\bar{P}(\mu_x, \mu_y) = \frac{n_c * P_c(\mu_x, \mu_y)}{(1 - n_c) * P_f(\mu_x, \mu_y) + n_c * P_c(\mu_x, \mu_y)} \quad (5)$$

De esta forma podemos encontrar las probabilidades de que una estrella pertenezca al cúmulo, solo basta definir un umbral para decidir si la estrella es del cúmulo o si pertenece al campo.

El único inconveniente de este procedimiento es que de antemano desconocemos las distribuciones P_c y P_f , pero a partir de los datos y haciendo uso del método de máxima verosimilitud, podemos encontrar los parámetros de las distribuciones mencionadas

anteriormente.

El método de máxima verosimilitud es una técnica usada en estadística para estimar los parámetros de una distribución de probabilidad, dados los datos observados. Consiste en maximizar una función de verosimilitud, es decir, la probabilidad de observar los datos dados ciertos valores de los parámetros de la distribución. En nuestro caso buscamos encontrar los valores de μ_{x0c} , μ_{y0c} , σ , μ_{x0f} , μ_{y0f} , σ_x , σ_y , ρ y n_c que maximizan esa función, de modo que las distribuciones $P_c(\mu_x, \mu_y)$ y $P_f(\mu_x, \mu_y)$ proporcionen la mejor descripción estadística de los datos observados. Para una revisión de las ecuaciones de verosimilitud revise Alfonso, J. E. (2019) [8].

Una forma de resolver este problema de optimización es calcular el logaritmo de la función de verosimilitud, de modo que usando la función `optimize` de la librería `scipy`, se pueda minimizar para encontrar los parámetros deseados. En este caso se usó el algoritmo Broyden-Fletcher-Goldfarb-Shanno con memoria limitada para minimizar el logaritmo de la verosimilitud. Este algoritmo permite estimar uno o más parámetros a partir del cálculo de gradientes y su convergencia es más rápida en comparación con otros algoritmos [9].

Una vez obtenidos los parámetros de las distribuciones, se calculó la probabilidad de que cada estrella del catálogo descargado pertenezca al cúmulo M41. Posteriormente se graficaron los diagramas vectoriales de puntos de las estrellas del cúmulo y del campo, así como diagramas magnitud-color. Estos se presentan en la sección de resultados.

4. Problemas encontrados y soluciones aplicadas

El principal problema a la hora de aplicar el método de máxima verosimilitud, para estimar los parámetros de las distribuciones $P_c(\mu_x, \mu_y)$ y $P_f(\mu_x, \mu_y)$, es encontrar valores iniciales sobre los cuales efectuar la minimización. Escoger valores arbitrarios puede desencadenar en que la optimización encuentre los parámetros que conllevan a un estancamiento en un mínimo local y no a una convergencia en el mínimo global. Para solucionar esto, es posible utilizar el diagrama vectorial de puntos de la figura 1 para estimar los centroides de las distribuciones y sus desviaciones.

La figura 2 muestra el mismo diagrama vectorial de puntos de la figura 1, con unas líneas azules que sirven de guía para estimar los valores iniciales de las distribuciones del cúmulo y el campo. Cada una de las líneas está alineada con los máximos de las distribuciones marginales mostradas en los histogramas, de este modo se estimó que los valores iniciales para los centroides del cúmulo son $\mu_{x0c} = -4,4$ mas y $\mu_{y0c} = -1,5$ mas. Dado que la densidad mostrada en el diagrama para el cúmulo está poco dispersa, se estimo que $\sigma = 0,5$ mas. Del mismo modo, los parámetros iniciales para el campo se estimaron como $\mu_{x0f} = 0$ mas y $\mu_{y0f} = 1,5$ mas, $\sigma_x = \sigma_y = 3$ mas, dado que

la dispersión es mayor, la correlación se estimó inicialmente como $\rho = 0$, dado que no existe una rotación aparente. Finalmente, la proporción de estrellas del cúmulo se estimó en 0,5 solo como un parámetro inicial que no indujera un sesgo inmediato.




Figura 2: Diagrama Vectorial de puntos cúmulo M41 y estrellas del campo. Las líneas azules corresponden a guías para encontrar los centroides de las distribuciones marginales de movimientos propios.

5. Resultados

El algoritmo de optimización Broyden-Fletcher-Goldfarb-Shanno arrojó que los parámetros que maximizan la verosimilitud son los que se muestran en la tabla 1.

Parámetro	Estimación inicial	Valor final optimizado
μ_{x0c}	-4.4	-4.37
μ_{y0c}	-1.5	-1.36
σ	0.5	0.17
μ_{x0f}	0.0	-0.59
μ_{y0f}	1.5	0.44
σ_x	3.0	4.63
σ_y	3.0	6.46
ρ	0	-0.25
n_c	0.5	0.26

Cuadro 1: Valores de los parámetros de las distribuciones $P_c(\mu_x, \mu_y)$ y $P_f(\mu_x, \mu_y)$. La segunda columna corresponde a las estimaciones iniciales basadas en el diagrama vectorial de puntos. La tercera columna muestra los valores finales optimizados por el método de máxima verosimilitud.

A partir de los parámetros se calcularon las distribuciones $P_c(\mu_x, \mu_y)$ y $P_f(\mu_x, \mu_y)$ y la probabilidad de que una estrella pertenezca al cúmulo dados sus movimientos propios, usando la ecuación 5. Se definió un umbral de 0.5 para decidir si una estrella pertenece o no al cúmulo y se encontró que de 2000 estrellas, 532 pertenecen al cúmulo y 1468 al campo. Estos números son congruentes si tenemos en cuenta que M41 es un cúmulo abierto, los cuales tienen entre 10^2 y 10^4 estrellas.

La figura 3 muestra el histograma de probabilidades de pertenencia de estrellas. La forma en U del histograma demuestra que el modelo ha logrado diferenciar las estrellas del campo y las del cúmulo con muy buena precisión. En los rangos de probabilidad de entre 0.2 y 0.8 hay frecuencias de máximo 10 estrellas, lo que demuestra que, teniendo en cuenta de se evaluaron 2000 estrellas, el modelo utilizado está bastante seguro de de cuáles estrellas pertenecen al cúmulo y cuáles pertenecen al campo.




Figura 3: Histograma de probabilidades de pertenencia de estrellas al cúmulo M41. Se definió un umbral de 0.5.

La figura 4 muestra el diagrama vectorial de puntos de la figura 1, pero con las estrellas del cúmulo segmentadas en color verde. Tal y como supusimos en un principio a partir de las distribuciones marginales mostradas en los histogramas de la figura 1, el cúmulo M41 corresponde a esa pequeña densidad cuyos movimientos propios en declinación y ascensión recta son muy similares. En la figura se muestra que hay estrellas catalogadas como campo con movimientos propios muy similares a las estrellas del cúmulo, por lo que se podría llegar a pensar que deberían ser parte de M41. Estas estrellas pueden ser precisamente las que se encuentran en el valle de probabilidades entre 0.2 y 0.5 del histograma de la figura 3, en dicha región el modelo no está completamente seguro de clasificarlas como campo, pero tampoco alcanza a clasificarlas como cúmulo a partir de los movimientos propios. Este es precisamente el límite del modelo analítico, no es posible clasificar estrellas como pertenecientes al cúmulo o al campo con total seguridad a partir únicamente de los movimientos propios. Es necesario incluir otras características de las estrellas como el paralaje o las magnitudes aparentes, para construir un modelo más robusto de pertenencia. Aquí es donde el Machine Learning se vuelve una opción viable y congruente con el problema a tratar.




Figura 4: Diagrama vectorial de puntos. Los puntos en verde corresponden a estrellas que pertenecen al cúmulo M41 con una probabilidad mayor a 0.5.

Por otro lado, la figura 5 muestra una gráfica de posición espacial (en declinación y ascensión recta) de las estrellas del cúmulo y del campo. Esta figura sirve para demostrar dos cosas, la primera es evidenciar que el problema de los gráficos de posiciones es que todas las estrellas, tanto del cúmulo como del campo, quedan dispersadas en un plano que impide identificar cuáles pertenecen al cúmulo. Por otro lado, la figura sirve para demostrar la utilidad de los diagramas vectoriales de puntos, pues como se mencionó antes, las estrellas de un mismo cúmulo poseen movimientos propios muy similares debido a que, en promedio, se encuentran a la misma distancia, lo que permite identificar densidades asociadas a las estrellas pertenecientes al cúmulo.




Figura 5: Gráfica de posiciones de las estrellas del cúmulo M41 y estrellas del campo en declinación y ascensión recta.

Finalmente, la figura 6 muestra el diagrama magnitud-color para las estrellas del campo y las estrellas pertenecientes al cúmulo M41 con una probabilidad mayor a 0.5. La figura muestra que las estrellas del cúmulo siguen la secuencia principal, hay estrellas tanto brillantes y calientes como estrellas menos brillantes y más frías. No se observa ninguna región de la secuencia principal que no esté poblada por estrellas del cúmulo, incluso hay estrellas con diferencias de 0.75 magnitudes, que corresponden a sistemas binarios. La figura también muestra un par de estrellas fuera de la secuencia principal que incluso podrían pertenecer a la rama de gigantes rojas, pero no hay evidencia suficiente para afirmarlo puesto que no se ve el codo al final de la secuencia principal en donde empieza dicha rama.




Figura 6: Diagrama magnitud-color de las estrellas del campo y las estrellas del cúmulo M41.

6. Conclusiones

En este informe hemos realizado un estudio de pertenencia de estrellas del cúmulo M41 a partir de datos del catálogo Gaia DR3. Para esto hemos construido distribuciones normales bivariadas asociadas al cúmulo y al campo. Con la principal diferencia de que las estrellas del cúmulo, al estar en promedio a la misma distancia, los movimientos propios en declinación y ascensión recta poseen las mismas desviaciones, de modo que el cúmulo puede identificarse como una densidad en un diagrama vectorial de puntos.

Para encontrar los parámetros de las distribuciones normales bivariadas se utilizó el método de máxima verosimilitud. La función de verosimilitud se maximizó haciendo uso de herramientas computacionales y el algoritmo Broyden-Fletcher-Goldfarb-Shanno. A partir de las distribuciones se utilizó el teorema de Bayes para calcular la probabilidad de que una estrella pertenezca al cúmulo, dados los movimientos propios en ascensión recta y declinación.

El modelo demostró estar bastante seguro de cuáles estrellas son o no parte del cúmulo M41 con un umbral del 0.5. Se encontró que de 2000 estrellas, 532 pertenecen

a M41, además de que en el valle de probabilidades entre 0.2 y 0.8, las frecuencias eran de máximo 10 estrellas, lo que demuestra que el modelo duda de muy pocas estrellas. Sin embargo, esta duda abre la puerta a preguntas sobre si solo tener en cuenta los movimientos propios de las estrellas para resolver el problema de pertenencia es suficiente. Este límite del modelo analítico sugiere que el uso de Machine Learning es adecuado para resolver el problema de pertenencia a partir no solo de los movimientos propios, sino también de otras variables como el paralaje y magnitudes aparentes.

El diagrama magnitud color de las estrellas del campo y de las catalogadas como del cúmulo M41 con una probabilidad mayor a 0.5, muestra una secuencia principal densamente poblada por las estrellas del cúmulo. Se lograron identificar inclusive la presencia de sistemas binarios, demostrando que el algoritmo de pertenencia aplicado es bastante robusto.

Referencias

- [1] B. J. Ramsey, *Exploring NGC 2287: An Investigation of Open Cluster Membership, Rotation, and a Curiously Bifurcated Main Sequence*. Rochester Institute of Technology, 2024.
- [2] L. S. Sparke and J. S. Gallagher, *Galaxies in the Universe: An Introduction*. Cambridge University Press, 2007.
- [3] A. Vallenari, A. G. Brown, T. Prusti, J. H. De Bruijne, F. Arenou, C. Babusiaux, M. Biermann, O. L. Creevey, C. Ducourant, D. W. Evans, *et al.*, “Gaia data release 3-summary of the content and survey properties,” *Astronomy & Astrophysics*, vol. 674, p. A1, 2023.
- [4] H. Karttunen, P. Kröger, H. Oja, M. Poutanen, and K. J. Donner, *Fundamental astronomy*. Springer, 2007.
- [5] S. Vasilevskis, A. Klemola, and G. Preston, “Relative proper motions of stars in the region of the open cluster ngc 6633,” *Astronomical Journal, Vol. 63, p. 387-395 (1958)*, vol. 63, pp. 387–395, 1958.
- [6] W. L. Sanders, “An improved method for computing membership probabilities in open clusters,” *Astronomy and Astrophysics*, vol. 14, pp. 226–236, 1971.
- [7] M. H. Slovak, “Maximum-likelihood method for determination of membership in open clusters,” *Astronomical Journal, v. 82, p. 818*, vol. 82, p. 818, 1977.
- [8] J. E. Alfonso, “Pertenencia de estrellas a cúmulos abiertos usando movimientos propios de gaia,” 2019.
- [9] “Optimization (scipy.optimize) - scipy v1.17.0 manual.”