

Estudio de pertenencia estelar en los cúmulos abiertos Coma Berenices y M41 mediante HDBSCAN y datos Gaia

Simón González López

13 de marzo de 2026

Resumen

En este trabajo se estudia el problema de pertenencia estelar en los cúmulos abiertos Coma Berenices y M41 utilizando datos del catálogo Gaia y un enfoque de aprendizaje automático no supervisado basado en HDBSCAN. Los resultados obtenidos del cúmulo M41 se compararon con los resultados obtenidos previamente con un modelo analítico basado en estadística Bayesiana. Para Coma Berenices se analizaron 5010 estrellas del catálogo Gaia DR2, y se encontró un clúster de 155 miembros que corresponde al cúmulo conocido, en concordancia con los 127 miembros reportados en la literatura. En el caso de M41, utilizando datos de Gaia DR3, HDBSCAN identificó un clúster principal de 579 estrellas con un valor promedio de silueta de 0.536. La comparación con el método Bayesiano muestra que HDBSCAN logra identificar 47 estrellas adicionales como posibles miembros del cúmulo. Los diagramas magnitud-color sugieren que estas estrellas siguen la secuencia principal del cúmulo, lo que refuerza la hipótesis de su pertenencia. Estos resultados muestran que HDBSCAN es una herramienta útil para la identificación de miembros de cúmulos abiertos, particularmente cuando se incluyen dimensiones adicionales como el paralaje. No obstante, la validación definitiva de los miembros identificados requiere información de catálogos de referencia que permitan evaluar la precisión de los métodos utilizados. Para acceder al código, visite la carpeta 3: *HDBSCAN* en el repositorio de GitHub en el siguiente link <https://github.com/sgonzalez38/Astrofisica-Observacional-con-Machine-Learning>.

1. Introducción

El estudio de pertenencia estelar a cúmulos abiertos es un problema fundamental en astrofísica observacional, ya que la correcta identificación de los miembros permite estudiar propiedades estelares como la edad, distancia y evolución dinámica de estos sistemas. Los cúmulos abiertos son sistemas gravitacionalmente ligados cuyas estrellas

se originaron de la misma nube molecular. Estas estrellas comparten propiedades físicas similares como la edad, la composición química, distancia y movimiento espacial. Por este motivo, los cúmulos abiertos son idóneos para el estudio de la evolución estelar [1,2]. Sin embargo, la identificación de sus miembros es un problema no trivial debido a la presencia de estrellas de campo que se proyectan en la misma región del cielo y pueden contaminar las muestras observacionales.

El lanzamiento del satélite Hipparcos en 1989 representó un avance significativo en la astrometría moderna, al proporcionar mediciones de posiciones, paralajes y movimientos propios, así como de cantidades fotométricas, para más de 100000 estrellas [3]. No obstante, el alcance y precisión de este catálogo limitaban el estudio detallado de estructuras estelares a distancias cortas. Tiempo después, la misión Gaia de la Agencia Espacial Europea revolucionó la astrometría al proporcionar medidas de posición, paralajes, movimientos propios, entre otras cantidades astrométricas y fotométricas, con una precisión sin precedentes para más de mil millones de estrellas en la Vía Láctea [4]. Las versiones más recientes del catálogo, como Gaia DR3 [5], han permitido estudiar con gran detalle la estructura y dinámica de cúmulos estelares, así como mejorar significativamente los métodos de identificación de miembros de cúmulos.

En este contexto, los cúmulos abiertos Coma Berenices y M41 constituyen ejemplos interesantes para el estudio de pertenencia estelar. El cúmulo Coma Berenices es uno de los cúmulos más cercanos al Sol (86 pc) y ha sido ampliamente estudiado en catálogos astrométricos recientes [6], donde se han identificado aproximadamente 127 miembros. Por otro lado, M41 es un cúmulo abierto localizado en la constelación Canis Major, ubicado a una distancia de 725pc del Sol, su edad se estima en torno a los 200 millones de años, por lo que es un cúmulo relativamente joven [1]. El análisis de estos cúmulos resulta particularmente útil para evaluar métodos de evaluación de pertenencia, ya que presentan diferentes grados de compacidad y contaminación por estrellas de campo.

Tradicionalmente, el problema de pertenencia estelar se ha abordado mediante métodos estadísticos que utilizan las distribuciones de movimientos propios y paralajes para distinguir entre estrellas del cúmulo y del campo. Entre estos enfoques se encuentran los métodos de máxima verosimilitud [7] y modelos Bayesianos, que permiten estimar probabilidades de pertenencia a partir de modelos paramétricos de las distribuciones observadas [8,9]. Sin embargo, en ocasiones los algoritmos analíticos se quedan cortos debido a que se limitan solamente a evaluar los movimientos propios en ascensión recta y declinación, por lo que se ha impulsado el uso de técnicas de aprendizaje automático para abordar el problema de pertenencia de manera más flexible.

En particular, los algoritmos de Clustering no supervisado permiten identificar agrupaciones naturales de estrellas (clusters) en el espacio de parámetros astrométricos sin necesidad de asumir modelos paramétricos específicos. Uno de los métodos de Cluste-

ring no supervisado más común es el HDBSCAN, un algoritmo basado en densidad que extiende el método DBSCAN mediante una estructura jerárquica que permite identificar clusters de densidades variables y separar de forma robusta el ruido [10, 11]. Este algoritmo ha demostrado ser particularmente útil en aplicaciones astronómicas, donde las distribuciones de estrellas en el espacio de parámetros astrométricos pueden presentar formas complejas y no gaussianas [12].

En este trabajo se estudia el problema de pertenencia estelar en los cúmulos abiertos Coma Berenices y M41 utilizando datos del catálogo Gaia. Se aplica el algoritmo de Clustering no supervisado HDBSCAN para identificar miembros potenciales de los cúmulos a partir de sus movimientos propios y paralajes. Los resultados obtenidos se comparan con los de un método analítico previamente desarrollado basado en estadística Bayesiana y método de máxima verosimilitud [13], con el objetivo de evaluar la utilidad de las técnicas de aprendizaje automático en la identificación de miembros de cúmulos abiertos.

2. Objetivos

- Realizar el estudio de pertenencia de estrellas al cúmulo M41 y Coma Berenices a partir de los datos Gaia.
- Comparar el algoritmo Bayesiano construido previamente con algoritmos no supervisados como HDBSCAN para realizar la tarea de pertenencia.
- Construir diagramas magnitud-color de las estrellas pertenecientes al cúmulo M41 y Coma Berenices.

3. Procedimiento

En este informe se aplican dos enfoques para resolver el problema de pertenencia. El primero es un enfoque analítico basado en estadística Bayesiana, cuyo algoritmo fue previamente desarrollado [13]. Mientras que el otro enfoque es uno de aprendizaje automático no supervisado basado en HDBSCAN [14]. A continuación se describe cómo se manipularon los datos tanto de Coma Berenices como de M41 para realizar el estudio de pertenencia.

3.1. Datos de Coma Berenices

Los datos de Coma Berenices fueron descargados del catálogo Gaia DR2. La figura 1 muestra el diagrama vectorial de puntos de los datos, en la cual se puede apreciar una densidad que corresponde al cúmulo Coma Berenices. Asimismo, se muestra el diagrama magnitud-color de las estrellas descargadas del catálogo, en este se puede apreciar una

secuencia principal muy poblada, en la que no todas las estrellas pertenecen al cúmulo Coma Berenices.




Figura 1: Izquierda: Diagrama Vectorial de puntos cúmulo Coma Berenices y estrellas del campo. Derecha: Diagrama magnitud-color del cúmulo Coma Berenices y estrellas del campo.

Para aplicar HDBSCAN primero se escogieron las dimensiones a tener en cuenta para el algoritmo de Clustering. Se escogieron los movimientos propios en ascensión recta y declinación, así como el paralaje, debido a que son características que comparten los miembros del cúmulo. El algoritmo HDBSCAN permitió obtener dos clusters más el ruido, cuyos detalles se mencionan en la sección de resultados. Asimismo se construyeron perfiles de silueta para evaluar el algoritmo de Clustering.

3.2. Datos de M41

Los datos fueron tomados del catálogo Gaia DR3. Para esto se hizo una búsqueda en cono de 1° y se filtró por paralaje. Dado que el cúmulo M41 está ubicado a 725pc y su diámetro es de 8pc , el filtrado por paralaje se hizo en $(725 \pm 30\text{pc})^{-1}$, es decir $1,3245 - 1,4388\text{ mas}$, esto con el objetivo de tener estrellas del cúmulo y suficientes estrellas del campo para resolver el problema de pertenencia.

La figura 2 muestra el diagrama vectorial de puntos de los datos descargados del catálogo Gaia, en este es posible observar una densidad que corresponde al cúmulo M41. La figura también muestra un diagrama magnitud-color de las estrellas del cúmulo y las del campo, en el que se puede diferenciar una secuencia principal.




Figura 2: Izquierda: Diagrama Vectorial de puntos cúmulo M41 y estrellas del campo. Derecha: Diagrama magnitud-color del cúmulo M41 y estrellas del campo.

Las dimensiones escogidas para HDBSCAN fueron las mismas previamente mencionadas para Coma Berenices, es decir, los movimientos propios en ascensión recta y en declinación, y el paralaje. El algoritmo logró identificar dos clusters y el ruido. Estos resultados se compararon con los obtenidos previamente por el algoritmo Bayesiano [13], se encontró que HDBSCAN encuentra más estrellas pertenecientes al cúmulo M41 en comparación algoritmo Bayesiano. Se realizaron diagramas magnitud-color comparando ambos métodos y se realizó perfiles de silueta para evaluar la calidad del algoritmo de Clustering.

4. Problemas encontrados y soluciones aplicadas

El problema fundamental del algoritmo de HDBSCAN es ajustar los hiperparámetros para obtener resultados de buena calidad. El hiperparámetro `min_cluster_size` se configuró en 100, esto debido a que es la cantidad mínima de estrellas que contiene un cúmulo abierto. Por otro lado, dado que estamos trabajando con tres dimensiones, se escogió un valor de `min_samples` de 6, esto con el fin de evitar que el algoritmo sea muy conservador y no identifique clusters poco densos. Del mismo modo, se escogió la métrica euclidiana como el hiperparámetro para calcular distancias.

5. Resultados

5.1. Coma Berenices

El algoritmo HDBSCAN aplicado a los datos de Coma Berenices da cuenta de la utilidad del modelo. El algoritmo encontró que en las 5010 estrellas descargadas, hay

dos clusters, uno de ellos con 2981 estrellas y otro con 155. La figura 3 muestra el diagrama vectorial de puntos de los datos de Coma Berenices, en el cual cada estrella está etiquetada dependiendo del clúster al que pertenece según HDBSCAN. Es posible notar que el clúster 1, que contiene 155 miembros, es una densidad de estrellas cuyos movimientos propios en ascensión recta y declinación son muy similares entre si, por lo que podemos afirmar que este cúmulo es Coma Berenices. Este cúmulo tiene en realidad 127 miembros [6], por lo que nuestros resultados son congruentes y tienen un error del 22 %.




Figura 3: Diagrama vectorial de puntos de los dos clusters y el ruido encontrados por HDBSCAN en los datos de Coma Berenices.

Para evaluar el desempeño del algoritmo de Clustering implementado, se construyeron los perfiles de silueta de la figura 4. Dicha figura muestra que las estrellas catalogadas como pertenecientes al clúster 1 (Coma Berenices) tienen una silueta promedio de 0.905, lo que quiere decir que dichas estrellas están debidamente asignadas al cúmulo Coma Berenices.




Figura 4: Perfil de silueta clusters encontrados en los datos de Coma Berenices.

La figura 5 muestra un diagrama vectorial de puntos de las estrellas de Coma Berenices y las estrellas del campo. Además, se muestra un diagrama magnitud-color de dichas estrellas, en el que se puede apreciar la secuencia principal, así como el codo al final de esta que representa la presencia de gigantes rojas en el cúmulo. Es posible que las estrellas que no pertenecen a la secuencia principal no formen parte realmente del cúmulo, pues como se mencionó previamente Coma Berenices solo posee 127 miembros. Dado que son pocas las estrellas catalogadas erróneamente, no existe una evidencia clara en las siluetas de la figura 4 que permita identificar con total seguridad estos casos como clasificaciones incorrectas. En consecuencia, los valores del coeficiente de silueta reflejan principalmente la compacidad del grupo de estrellas con movimientos propios similares, más que la presencia de contaminantes individuales del campo estelar.




Figura 5: Izquierda: Diagrama vectorial de puntos de las estrellas de Coma Berenices agrupadas a partir de HDBSCAN. Derecha: Diagrama magnitud-color de las estrellas pertenecientes a Coma Berenices encontradas a partir de HDBSCAN.

5.2. M41

Al aplicar el algoritmo HDBSCAN a las 2000 estrellas del catálogo de M41, se encontraron 2 clsters de 579 y 374 estrellas. La figura 6 muestra el diagrama vectorial de puntos de los dos clusters encontrados y el ruido. La figura muestra que el clúster 0, que contiene 579 estrellas, representa una densidad de estrellas en el diagrama vectorial de puntos cuyos movimientos propios en ascensión recta y declinación son muy similares entre sí, por lo que es posible afirmar que dicho clúster corresponde a M41. Esto puede confirmarse con el diagrama magnitud-color de la figura 7, en la cual las estrellas del clúster 0 siguen claramente una secuencia principal con algunos sistemas binarios inclusive.




Figura 6: Diagrama vectorial de puntos de los dos clusters y el ruido encontrados por HDBSCAN en los datos de M41.




Figura 7: Diagrama magnitud-color de los dos clusters y el ruido encontrados por HDBSCAN en los datos de M41.

Para evaluar el desempeño del algoritmo de Clustering implementado, se construyeron los perfiles de silueta que se muestran en la figura 8. El perfil de silueta del clúster

0, que asociamos con M41, tiene un valor promedio por estrella de 0.536. Este valor es menor a lo encontrado para Coma Berenices, por lo que se puede afirmar que el modelo tuvo algunos inconvenientes asociando las estrellas al cúmulo de M41. Sin embargo, dado que es mayor a 0.5, existe mucha fiabilidad de que las estrellas catalogadas como pertenecientes a M41 si comparten características suficientes para ser consideradas como miembros del mismo cúmulo.




Figura 8: Perfil de silueta clusters encontrados en los datos de M41.

Una vez encontradas las estrellas de M41 mediante el algoritmo no supervisado basado en HDBSCAN, se compararon con los miembros encontrados mediante el algoritmo bayesiano construido en [13]. La figura 9 muestra un diagrama vectorial de puntos de las estrellas de M41 encontradas mediante el algoritmo analítico y por HDBSCAN. Se puede apreciar que HDBSCAN cataloga estrellas como pertenecientes a M41 que tienen una mayor dispersión en movimientos propios en comparación con las catalogadas por el método analítico. Esto es precisamente porque HDBSCAN tiene tres dimensiones, los movimientos propios como en el método analítico, pero también tiene en cuenta el paralaje. Como el paralaje está relacionado con la distancia, y los miembros del cúmulo están, en promedio, a la misma distancia, HDBSCAN logra rescatar las estrellas que tienen una mayor dispersión en los movimientos propios, pero las cataloga como miembros del cúmulo debido a su cercanía en distancia.




Figura 9: Diagrama vectorial de puntos de las estrellas catalogadas como miembros de M41 encontradas con el algoritmo analítico y por HDBSCAN.

Además, todas las estrellas encontradas con el método analítico también se encontraron con HDBSCAN, por lo que ambos algoritmos funcionan muy bien para evaluar la pertenencia de las estrellas que tienen movimientos propios muy similares, es decir que no tengan tanta dispersión en el diagrama vectorial de puntos. Pero HDBSCAN, gracias a su tercera dimensión de paralaje, logra agrupar estrellas con movimientos propios más dispersos pero que aún son miembros del cúmulo. Estas estrellas son precisamente las que se encuentran en la periferia del cúmulo. La figura 10 muestra los diagramas magnitud-color de las estrellas de M41 encontradas con el método analítico y por HDBSCAN. Es posible ver que ambos métodos muestran estrellas en la secuencia principal y algunos sistemas binarios cuyas diferencias en magnitud es de 0.75. La figura muestra también el diagrama magnitud-color de las 47 estrellas que se encontraron por HDBSCAN y no en el analítico, dichas estrellas siguen también una secuencia principal igual a la del cúmulo M41, por lo que se refuerza la idea de que estas estrellas sí son miembros de dicho cúmulo.




Figura 10: Izquierda: Diagrama magnitud color de las estrellas catalogadas como miembros de M41 por HDBSCAN y el método analítico. Derecha: Diagrama magnitud-color de las estrellas encontradas por HDBSCAN que no fueron catalogadas por el método analítico.

Este análisis sugiere que HDBSCAN arroja mejores resultados que el algoritmo analítico, ya que hemos logrado identificar más estrellas pertenecientes al cúmulo gracias a que se tuvo en cuenta el paralaje. Sin embargo, no podemos afirmar cuál de los dos métodos es mejor realmente, pues debemos conocer cuáles estrellas de verdad pertenecen a M41. Con este dato podemos calcular cantidades de interés como la especificidad y la sensibilidad que sí permiten evaluar los modelos de clasificación de manera óptima. Por ejemplo, HDBSCAN encontró 47 estrellas adicionales al método tradicional, los diagramas magnitud-color sugieren que sí son parte del cúmulo, pero esto puede ser simplemente una correlación fortuita. La única forma de saber si HDBSCAN es mejor, es conocer de antemano si estas 47 estrellas adicionales sí son parte de M41 o no.

6. Conclusiones

En este informe se realizó un estudio del problema de pertenencia de estrellas a los cúmulos abiertos Coma Berenices y M41 utilizando datos del catálogo Gaia. Para esto se adoptaron dos enfoques distintos, uno basado en estadística Bayesiana previamente construido y otro algoritmo no supervisado basado en HDBSCAN.

Los resultados muestran que HDBSCAN es capaz de identificar regiones de sobredensidad en el espacio de movimientos propios y paralaje, permitiendo recuperar clusters estelares que corresponden a los cúmulos analizados. EN el caso de Coma Berenices el algoritmo identificó un cluster de 155 estrellas, cercano al número reportado en la literatura (127), con un coeficiente de silueta promedio de 0.905, lo que indica una

separación clara entre estrellas del cúmulo y estrellas del campo. Para M41, el algoritmo encontró un cluster principal de 579 estrellas con una silueta promedio de 0.536, valor que sugiere una agrupación compacta aunque con mayor dispersión en el espacio de movimientos propios y paralaje.

La comparación del método HDBSCAN con el algoritmo analítico para el cúmulo M41 muestra que HDBSCAN logra identificar 47 estrellas adicionales como posibles miembros de M41. Dichas estrellas siguen la secuencia principal en el diagrama magnitud-color, lo que sugiere que podrían pertenecer realmente al cúmulo. Estos resultados demuestran que el uso de paralaje como dimensión adicional permite recuperar miembros con movimientos propios más dispersos. Sin embargo, la ausencia de una muestra de referencia con membresía confirmada impide determinar con certeza cuál de los métodos produce clasificaciones más precisas. En consecuencia, aunque HDBSCAN muestra un desempeño prometedor, es necesario complementar este tipo de análisis con catálogos de referencia que permitan validar de manera rigurosa los resultados obtenidos.

Referencias

- [1] B. J. Ramsey, *Exploring NGC 2287: An Investigation of Open Cluster Membership, Rotation, and a Curiously Bifurcated Main Sequence*. Rochester Institute of Technology, 2024.
- [2] L. S. Sparke and J. S. Gallagher, *Galaxies in the Universe: An Introduction*. Cambridge University Press, 2007.
- [3] L. Lindegren, J. Kovalevsky, E. Hoeg, U. Bastian, P. Bernacca, M. Crézé, F. Donati, M. Grenon, M. Grewing, F. Van Leeuwen, *et al.*, “The hipparcos catalogue,” *Astronomy & Astrophysics-A&A*, vol. 323, no. 1, pp. 49–52, 1997.
- [4] A. G. Brown, A. Vallenari, T. Prusti, J. De Bruijne, F. Mignard, R. Drimmel, C. Babusiaux, C. Bailer-Jones, U. Bastian, M. Biermann, *et al.*, “Gaia data release 1-summary of the astrometric, photometric, and survey properties,” *Astronomy & Astrophysics*, vol. 595, p. A2, 2016.
- [5] A. Vallenari, A. G. Brown, T. Prusti, J. H. De Bruijne, F. Arenou, C. Babusiaux, M. Biermann, O. L. Creevey, C. Ducourant, D. W. Evans, *et al.*, “Gaia data release 3-summary of the content and survey properties,” *Astronomy & Astrophysics*, vol. 674, p. A1, 2023.
- [6] S. Koposov, G. Collaboration, *et al.*, “Gaia data release 2. observational hertzprung-russell diagrams,” *Astronomy & Astrophysics*, vol. 616, 2018.

- [7] M. H. Slovak, “Maximum-likelihood method for determination of membership in open clusters,” *Astronomical Journal*, v. 82, p. 818, vol. 82, p. 818, 1977.
- [8] S. Vasilevskis, A. Klemola, and G. Preston, “Relative proper motions of stars in the region of the open cluster ngc 6633.,” *Astronomical Journal*, Vol. 63, p. 387-395 (1958), vol. 63, pp. 387–395, 1958.
- [9] W. L. Sanders, “An improved method for computing membership probabilities in open clusters,” *Astronomy and Astrophysics*, vol. 14, pp. 226–236, 1971.
- [10] R. J. Campello, D. Moulavi, and J. Sander, “Density-based clustering based on hierarchical density estimates,” in *Pacific-Asia conference on knowledge discovery and data mining*, pp. 160–172, Springer, 2013.
- [11] L. McInnes, J. Healy, S. Astels, *et al.*, “hdbscan: Hierarchical density based clustering.,” *J. Open Source Softw.*, vol. 2, no. 11, p. 205, 2017.
- [12] W. S. Dias, H. Monteiro, B. Alessi, J. R. Lépine, and R. P. Alves, “Discovery of 178 open clusters with gaia dr3,” *The Astronomical Journal*, vol. 171, no. 1, p. 24, 2026.
- [13] S. González, “Estudio de pertenencia de estrellas al cúmulo m41 a partir de datos gaia dr3.” <https://github.com/sgonzalez38/Astrofisica-Observacional-con-Machine-Learning/Lab2:Pertenencia/main.pdf>, 2026. GitHub repository, accessed: 2026-03-13.