

Identificación de Cúmulos Abiertos a 200 pc del Sol con datos Gaia DR3 y HDBSCAN

Simón González, Daniel Fajardo

10 de abril de 2026

Resumen

Este trabajo presenta la identificación y caracterización de cúmulos abiertos localizados a una distancia de hasta 200 pc del Sol, utilizando datos astrométricos y fotométricos del catálogo Gaia DR3. Para abordar el problema de la pertenencia estelar y la segregación del ruido de fondo, se implementó el algoritmo de clustering no supervisado basado en densidad HDBSCAN, aplicado sobre un espacio de parámetros que incluye movimientos propios (μ_α , μ_δ) y paralaje (ϖ). A partir de un procesamiento por regiones espaciales y una validación exhaustiva mediante diagramas vectorial de puntos, magnitud-color, perfiles radiales de densidad, histogramas de distancia y perfiles de silueta, se identificaron con éxito siete (7) candidatos a cúmulos abiertos: Hyades, Melotte 20, IC 2391, NGC 2632, NGC 2451A, Coma Berenice y HSC 759. Los resultados muestran una alta consistencia con la literatura astronómica actual, validando la eficacia de las técnicas de *machine learning* para discernir estructuras estelares ligadas en regiones de alta densidad de datos. Finalmente, se discuten las limitaciones del modelo respecto al umbral de miembros estelares y la necesidad de optimizar hiperparámetros para la detección de cúmulos adicionales.

Palabras clave: Cúmulos abiertos, Gaia DR3, HDBSCAN, Machine Learning, Astrometría, Pertenencia estelar.

Para acceder al código, visite el repositorio de GitHub: <https://github.com/sgonzalez38/Astrofisica-Observacional-con-Machine-Learning>.

1. Introducción

El estudio de pertenencia estelar a cúmulos abiertos es un problema fundamental en astronomía observacional, ya que identificar correctamente los miembros de un cúmulo, permite estudiar propiedades estelares como la edad, distancia, evolución de las estrellas y otras propiedades de interés. Los cúmulos abiertos son sistemas de entre 100 y 10000

estrellas gravitacionalmente ligadas, las cuales se formaron a partir de la misma nube molecular. Es por este motivo que las estrellas de un cúmulo comparten características como la edad, la composición química, la distancia y los movimientos propios. Por estas razones, los cúmulos abiertos son idóneos para el estudio de la evolución estelar [1, 2]. Sin embargo, la identificación de los miembros de un cúmulo no es un problema fácil debido a la presencia de estrellas de campo que se proyectan en la misma región del cielo y pueden contaminar las muestras observacionales.

Para solucionar el problema de pertenencia se han implementado algoritmos de Machine Learning en particular, los algoritmos de Clustering no supervisado permiten identificar agrupaciones naturales de estrellas (clusters) en el espacio de parámetros astrométricos sin necesidad de asumir modelos paramétricos específicos como distribuciones bivariadas. HDBSCAN es un algoritmo basado en densidad que extiende el método DBSCAN mediante una estructura jerárquica que permite identificar clusters de densidades variables y separar de forma robusta el ruido [3, 4]. Este algoritmo ha demostrado ser particularmente útil en aplicaciones astronómicas, donde las distribuciones de estrellas en el espacio de parámetros astrométricos pueden presentar formas complejas y no gaussianas [5].

La literatura astronómica actual [6] reporta un total de 30 cúmulos abiertos a una distancia de 200 pc del Sol. La Tabla 1 muestra los 30 cúmulos abiertos con sus coordenadas en ascensión recta y declinación, así como su distancia y la cantidad de estrellas.

En este trabajo se aborda el problema de pertenencia estelar a cúmulos abiertos de estrellas a distancias de hasta 200 pc del Sol. Para esto se utilizaron datos del catálogo Gaia DR3 [7] y algoritmos de Clustering no supervisado como HDBSCAN para identificar posibles candidatos a cúmulos abiertos, a partir de movimientos propios en ascensión recta y declinación, y paralaje. Los resultados obtenidos se contrastaron con los cúmulos ya identificados por la comunidad astronómica [6].

2. Objetivos

- Identificar cúmulos abiertos a 200 pc del sol a partir de datos Gaia DR3 y herramientas de Clustering no supervisado como HDBSCAN.
- Comparar los candidatos a cúmulos encontrados con los cúmulos abiertos reportados en la literatura astronómica.
- Realizar diagramas magnitud-color de los cúmulos abiertos encontrados.

Nombre	RA (deg)	Dec (deg)	Distancia (pc)	Miembros
Alessi 13	51.99	-35.77	104.25	144
Alessi 84	110.51	55.38	198.30	1069
HSC 396	317.19	-3.67	99.14	110
HSC 749	358.47	3.46	121.15	240
HSC 759	225.15	59.39	95.96	283
HSC 976	10.00	79.32	163.08	311
HSC 1340	61.30	21.99	120.09	180
HSC 1438	60.27	8.34	147.62	94
HSC 1542	93.72	15.55	152.98	87
HSC 2303	169.14	-35.60	154.64	169
HSC 2468	182.23	-51.54	108.98	222
HSC 2505	185.02	-64.10	105.85	123
HSC 2636	204.89	-44.48	133.88	321
HSC 2733	228.06	-44.53	144.17	141
HSC 2907	244.77	-24.45	154.58	284
HSC 2986	285.32	-36.88	148.05	475
IC 2391	130.26	-53.04	150.19	607
IC 2602	160.97	-64.39	150.55	583
Melotte 20	51.33	49.12	173.58	2544
Melotte 22 (Pleiades)	56.68	24.11	134.84	1763
Melotte 25 (Hyades)	66.71	16.08	47.19	976
Melotte 111 (Coma Ber.)	186.02	26.42	85.25	360
NGC 2632 (Praesepe)	130.09	19.67	183.49	1629
NGC 2451A	115.97	-38.24	190.08	1239
OCSN 92	231.56	-36.06	138.17	129
OCSN 96	240.43	-22.71	140.61	213
Platais 3	68.41	71.49	177.21	450
Platais 8	136.90	-59.31	133.59	673
Platais 9	138.32	-43.56	185.26	364
UPK 640	249.69	-39.51	173.86	779

Cuadro 1: Cúmulos Abiertos a 200 pc del Sol identificados con Gaia DR3 [6].

3. Procedimiento

En este informe se utilizaron datos, provistos por Santiago Henao, de estrellas a 200 pc del Sol, tomados del catálogo Gaia DR3 mediante una búsqueda en cono de 1° . En total se descargaron 3217487 estrellas con datos de ascensión recta y declinación, movimientos propios, paralaje y datos fotométricos.

Los datos de Gaia fueron divididos en 64 regiones espaciales, en ascensión recta y

declinación, de igual tamaño. Dado que un cúmulo abierto tiene típicamente más de 100 estrellas, se descartaron las regiones con menos de 100 estrellas. Para las demás regiones se extrajeron datos de movimientos propios en ascensión recta y declinación, así como el paralaje y datos fotométricos. Los movimientos propios y el paralaje se utilizaron como dimensiones para correr HDBSCAN, mientras que los datos fotométricos se usaron para graficar los diagramas magnitud-color de los candidatos a cúmulos.

Los hiperparámetros utilizados en HDBSCAN fueron `min_cluster_size` de 100 dado que es el número mínimo típico de estrellas en un cúmulo abierto y `min_samples` de 6 para evitar que el modelo fuese demasiado conservador y no logre identificar clusters poco densos. Para cada región y clusters encontrados por HDBSCAN se realizaron gráficas de diagramas vectoriales de puntos, diagramas magnitud-color, histograma de distancias, perfiles radiales y perfiles de silueta para evaluar el rendimiento del algoritmo de Clustering. De esta manera, mediante inspección visual se seleccionaron las regiones con posibles cúmulos abiertos para un estudio más detallado.

Una vez seleccionados los candidatos a cúmulos abiertos, se calcularon los centros espaciales de los candidatos como la mediana de los datos de ascensión recta y de declinación de cada una de las estrellas del candidato. De esta manera, conociendo su centro, su distancia y el número de estrellas, se hizo una comparación con los datos reportados en literatura astronómica [6], con el objetivo de contrastar los cúmulos encontrados con HDBSCAN con los cúmulos ya clasificados por la comunidad astronómica.

4. Problemas encontrados y soluciones aplicadas

El mayor problema en el desarrollo de este informe fue identificar si los clusters identificados con HDBSCAN son realmente cúmulos abiertos o no. Para esto estudiamos cinco propiedades fundamentales, el diagrama vectorial de puntos, el diagrama magnitud-color, el histograma de distancias, el perfil radial y el perfil de siluetas.

El diagrama vectorial de puntos permite evaluar si los cúmulos encontrados por HDBSCAN si representan sobredensidades en los movimientos propios en ascensión recta y declinación. Recordemos que las estrellas en un cúmulo abierto comparten un origen común y por tanto sus movimientos propios son muy similares. Por otro lado, el diagrama magnitud-color nos permite identificar si el candidato a cúmulo posee una secuencia principal, en caso de que las estrellas no sigan esa secuencia, se descarta el candidato. Asimismo, el histograma de distancias permite identificar si un cluster es un cúmulo abierto ya que, en promedio las estrellas están a la misma distancia, por lo que el histograma debe tener un pico claro y colas suaves. Esto quiere decir que si el histograma refleja un crecimiento continuo a medida que crece la distancia, el candidato se descarta. De la misma manera, el perfil radial debe presentar una densidad

de miembros a distancias muy cercanas al centroide del cúmulo y colas no mayores a 15 pc. Finalmente, el perfil de silueta permite identificar la confiabilidad con la que HDBSCAN identificó los clusters, un valor de silueta cercano a 1 indica que la estrella está bien catalogada en el cluster, mientras que un valor de silueta de 0 o incluso negativo, indica que la estrella fue catalogada erroneamente como perteneciente al cluster con una alta probabilidad.

5. Resultados

Basándonos en un análisis exhaustivo de parámetros estructurales y fotométricos, hemos identificado un total de siete (7) candidatos a cúmulos abiertos. Los criterios de selección incluyeron:

- **Recuento de miembros:** Evaluación estadística de la densidad estelar local.
- **Diagrama vectorial de puntos (VPD):** Agrupamiento en el espacio de movimientos propios.
- **Diagramas magnitud-Color (CMD):** Identificación de una secuencia principal clara y bien definida para las estrellas candidatas.
- **Distribución espacial:** Los histogramas de distancias revelaron una sobredensidad significativa centrada en el centroide de cada cluster, con una caída marcada de la población estelar al alcanzar radios cercanos a los 15 pc.
- **Perfiles de densidad radial:** Se observó una distribución decreciente desde el centro, caracterizada por presentar alas no pesadas, consistente con sistemas estelares ligados.
- **Perfiles de silueta:** Aquellos clusters con una silueta mayor a 0.5, indicando alta probabilidad de que las estrellas están bien clasificadas como miembros del clustes.

A partir de la distancia calculada al centroide y su posición en coordenadas ecuatoriales (α, δ), se procedió a la validación cruzada con la literatura astronómica. En la Tabla 2 se presentan las coordenadas de los centroides de los candidatos y su respectiva asociación con cúmulos abiertos reportados previamente.

Las Figuras 1 a 7 presentan el análisis diagnóstico para cada objeto, incluyendo el diagrama vectorial de puntos (VPD), el diagrama magnitud-color (CMD), el histograma de distancias y el perfil de densidad radial.

Candidato	RA ($^{\circ}$)	Dec ($^{\circ}$)	Distancia (pc)	Asociación
C1	67.21	+16,36	47.6	Hyades
C2	52.75	+49,38	177.5	Melotte 20
C3	130.12	-52,94	151.8	IC 2391
C4	129.95	+19,54	184.9	NGC 2632
C5	145.35	-38,20	188.5	NGC 2451A
C6	192.48	+27,64	86.9	Coma Berenice
C7	210.87	+54,71	96.4	HSC 759

Cuadro 2: Coordenadas y asociación de los candidatos a cúmulos abiertos identificados.




Figura 1: Diagnóstico del Candidato 1: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 2: Diagnóstico del Candidato 2: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 3: Diagnóstico del Candidato 3: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 4: Diagnóstico del Candidato 4: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 5: Diagnóstico del Candidato 5: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 6: Diagnóstico del Candidato 6: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.




Figura 7: Diagnóstico del Candidato 7: (a) VPD, (b) CMD, (c) Histograma de distancias y (d) Perfil radial.

El candidato a cúmulo C1, mostrado en la Figura 1, que corresponde a Hyades, exhibe una secuencia principal bien definida, incluyendo algunos sistemas binarios, enanas blancas y posibles gigantes rojas. Sin embargo, el turn-off no está bien definido y por tanto no es posible aseverar con seguridad la presencia de gigantes.

Por otro lado, el candidato a cúmulo C2, mostrado en la Figura 2, que corresponde a Melotte 20, resalta por presentar una secuencia principal bien definida y la presencia de algunas enanas blancas. Asimismo, existen algunos outliers que posiblemente se ubican en la rama horizontal, lo que podría significar la presencia de estrellas variables.

El candidato a cúmulo C3 de la Figura 3 corresponde al cúmulo abierto IC 2391. Este cúmulo presenta el comportamiento más cercano al ideal de un grupo de estrellas jóvenes pertenecientes a un cúmulo abierto.

Por otra parte el cúmulo C4 de la Figura 4, que corresponde a NGC 2632 muestra presencia de enanas blancas y estrellas en la secuencia principal. Este comportamiento es similar al del candidato C1 previamente descrito.

El candidato a cúmulo C5 mostrado en la Figura 5 corresponde a NGC2451A. Este cúmulo exhibe una secuencia principal con sistemas binarios, además de enanas blancas. El perfil radial sugiere que no se ha determinado adecuadamente el centroide del cúmulo. Esto se puede explicar debido a la presencia de estrellas en el límite de detección del instrumento (muy débiles), posiblemente mal catalogadas como miembros del cúmulo.

El candidato C6 de la Figura 6, que corresponde a Coma Berenice muestra una secuencia principal bien definida, con un turn-off marcado, así como enanas blancas. El perfil radial muestra que el centroide del cúmulo no fue calculado de forma adecuada, esto posiblemente por la inclusión de miembros no pertenecientes al cúmulo.

De manera similar al candidato C3, el candidato C7 que corresponde a HSC 759, muestra un comportamiento casi ideal de estrellas jóvenes dentro de un cúmulo abierto. Sin embargo, existen algunas estrellas dentro del límite de detección con altos errores en la medición de sus parámetros. Los cuales afectaron el correcto cálculo del centroide del cúmulo.

Finalmente, bajo los hiperparámetros usados en HDBSCAN, en especial el `min_cluster_size`, no es posible identificar los cúmulos HSC 1438 y HSC 1542, ya que estos presentan menos de 100 estrellas. Para hacer una búsqueda mucho más exhaustiva y lograr catalogar los 30 cúmulos reportados [6], es necesario implementar características de clasificación adicionales que permitan resolver los casos ambiguos que el modelo no es capaz de catalogar con alta certeza.

6. Conclusiones

La realización de este laboratorio permitió la identificación exitosa de siete candidatos a cúmulos abiertos en el entorno solar cercano mediante el uso de datos del catálogo Gaia DR3. La implementación del algoritmo de clustering no supervisado HDBSCAN demostró ser una herramienta sumamente robusta para la segregación de estructuras estelares en el espacio de parámetros astrométricos. Al procesar simultáneamente los movimientos propios y el paralaje, el algoritmo logró diferenciar de manera efectiva las agrupaciones físicas del ruido de fondo generado por las estrellas de campo, probando que el aprendizaje automático es una metodología eficiente para abordar problemas de pertenencia estelar en regiones de alta densidad de datos.

La validez física de los grupos identificados se confirmó a través del análisis de los diagramas Color-Magnitud (CMD). La presencia de una secuencia principal clara y bien definida en todos los candidatos asegura que estas agrupaciones no son simples fluctuaciones estadísticas de densidad, sino sistemas ligados compuestos por estrellas de edad y composición química similares. Asimismo, la concordancia entre los histogramas de distancias y los perfiles de densidad radial, los cuales mostraron sobredensidades centra-

das y una caída poblacional marcada hacia los 15 pc, refuerza la naturaleza estructural de estos cúmulos como entidades gravitacionalmente ligadas con límites físicos definidos.

Finalmente, el proceso de validación cruzada con la literatura astronómica permitió la asociación exitosa de los siete candidatos identificados con cúmulos abiertos reportados previamente, incluyendo sistemas prominentes como las Hyades, Melotte 20, IC 2391, NGC 2632, NGC2451A, Coma Berenice y HSC 759. La coincidencia plena entre los centroides calculados y los registros bibliográficos subraya la alta precisión del flujo de trabajo implementado, demostrando que la combinación de datos de Gaia DR3 con algoritmos de clustering por densidad permite una caracterización fiel de la vecindad solar. Este nivel de concordancia valida la metodología utilizada para la remoción de contaminación estelar y posiciona este enfoque como una herramienta confiable para el estudio de la dinámica y evolución de sistemas estelares ligados a distancias próximas al Sol. Para mejorar la capacidad del modelo en resolver el problema de pertenencia estelar, se requiere modificar los hiperparámetros y explorar otras características de clasificación que permitan reducir las ambigüedades en el proceso asignación de grupos.

Referencias

- [1] B. J. Ramsey, *Exploring NGC 2287: An Investigation of Open Cluster Membership, Rotation, and a Curiously Bifurcated Main Sequence*. Rochester Institute of Technology, 2024.
- [2] L. S. Sparke and J. S. Gallagher, *Galaxies in the Universe: An Introduction*. Cambridge University Press, 2007.
- [3] R. J. Campello, D. Moulavi, and J. Sander, “Density-based clustering based on hierarchical density estimates,” in *Pacific-Asia conference on knowledge discovery and data mining*, pp. 160–172, Springer, 2013.
- [4] L. McInnes, J. Healy, S. Astels, *et al.*, “hdbscan: Hierarchical density based clustering,” *J. Open Source Softw.*, vol. 2, no. 11, p. 205, 2017.
- [5] W. S. Dias, H. Monteiro, B. Alessi, J. R. Lépine, and R. P. Alves, “Discovery of 178 open clusters with gaia dr3,” *The Astronomical Journal*, vol. 171, no. 1, p. 24, 2026.
- [6] P. Liu, M. Fang, Y.-L. S. Tsai, X. Pang, F. Wang, and X. Fu, “Revisiting open clusters within 200 pc in the solar neighborhood with gaia dr3,” *The Astronomical Journal*, vol. 169, no. 6, p. 326, 2025.
- [7] A. Vallenari, A. G. Brown, T. Prusti, J. H. De Bruijne, F. Arenou, C. Babusiaux, M. Biermann, O. L. Creevey, C. Ducourant, D. W. Evans, *et al.*, “Gaia data re-

lease 3-summary of the content and survey properties,” *Astronomy & Astrophysics*, vol. 674, p. A1, 2023.